

İSTANBUL TOPKAPI ÜNİVERSİTESİ

Durukan Esmeray (25221602004)

DERİN ÖĞRENME DERSİ

FİNAL ÖDEVİ RAPORU

YOLOv8 Tabanlı Derin Öğrenme Yaklaşımlarıyla

Beyin Tümörü Tespiti

Model: YOLOv8n (Transfer Learning)

Görev: Nesne Tespiti (Object Detection)

Tarih: Haziran 2026

1. Giriş ve Proje Amacı

Bu çalışmada, manyetik rezonans (MR) görüntülerinde beyin tümörünün otomatik tespiti problemi ele alınmıştır. Ara sınav ödevinden farklı olarak bu projede, görüntünün yalnızca sınıflandırılması (classification) değil, tümörün görüntü içindeki konumunun da kutu (bounding box) ile belirlenmesi gereken bir nesne tespiti (object detection) görevi söz konusudur.

Bu amaçla, gerçek zamanlı nesne tespitinde yaygın olarak kullanılan YOLOv8 (You Only Look Once, sürüm 8) mimarisi tercih edilmiştir. COCO veri seti üzerinde önceden eğitilmiş yolov8n.pt ağırlıkları transfer learning yöntemiyle kullanılarak, sınırlı sayıda MR görüntüsüyle dahi etkili bir tümör dedektörü geliştirilmesi hedeflenmiştir.

Projenin temel hedefleri:

- YOLOv8 modeliyle MR görüntülerinden beyin tümörü tespiti yapmak.
- Model başarımını mAP, Precision, Recall ve Confusion Matrix gibi standart nesne tespiti metrikleriyle değerlendirmek.
- Transfer learning ve veri artırma (data augmentation) stratejilerini uygulamak.
- Tespit sonuçlarını görselleştirmek ve modelin güvenilirliğini analiz etmek.

2. Veri Seti

2.1 Veri Kaynağı

Veri seti, Ultralytics tarafından sağlanan açık kaynaklı 'Brain Tumor Detection' veri setidir. Veri seti YOLO nesne tespiti formatında etiketlenmiş MR görüntülerinden oluşmaktadır.

- Kaynak: <https://github.com/ultralytics/assets/releases/download/v0.0.0/brain-tumor.zip>
- Dokümantasyon: <https://docs.ultralytics.com/tr/datasets/detect/brain-tumor/>

2.2 Veri Seti Yapısı

Veri seti, eğitim (train) ve doğrulama (validation) olmak üzere iki alt kümeye ayrılmış olarak gelmektedir:

Alt Küme	Görüntü Sayısı	Açıklama
Eğitim (train)	893	878 etiketli + 15 tümörsüz arka plan görüntüsü
Doğrulama (val)	223	Model performansının ölçüldüğü küme
Toplam	1.116	—

Veri setinde iki sınıf bulunmaktadır: 0 = negative (negatif), 1 = positive (pozitif). Etiketler YOLO formatındadır; her görüntünün yanındaki .txt dosyasında her satır 'sınıf_no x_merkez y_merkez genişlik yükseklik' biçiminde ve koordinatlar görüntü boyutuna göre [0,1] aralığında normalize edilmiş olarak yer alır.

2.3 Veri Tanım Dosyası (YAML)

YOLOv8, eğitim için veri yollarını ve sınıf bilgilerini bir YAML dosyasından okur. Veri setiyle birlikte gelen brain-tumor.yaml dosyasının içeriği:

```
path: brain-tumor
train: images/train    # 893 görüntü
val: images/val        # 223 görüntü
names:
  0: negative
  1: positive
```

3. Yöntem ve Model Mimarisi

3.1 YOLOv8 — Transfer Learning

YOLOv8, tek aşamalı (single-stage) bir nesne tespiti mimarisidir. Görüntüyü tek geçişte işleyerek hem nesnelerin sınıfını hem de konumunu (bounding box) aynı anda tahmin eder; bu sayede yüksek hız ve doğruluk sağlar. Mimari üç ana bölümden oluşur: öznitelik çıkaran omurga (backbone), öznitelikleri farklı ölçeklerde birleştiren boyun (neck) ve tahminleri üreten baş (head).

Bu çalışmada modelin en küçük varyantı olan yolov8n (nano) kullanılmıştır. COCO veri seti üzerinde önceden eğitilmiş ağırlıklar yüklenmiş (transfer learning), böylece modelin daha önce öğrendiği genel görsel öznitelikler (kenar, doku, şekil) beyin tümörü tespiti görevine aktarılmıştır. Çıkış katmanı, veri setindeki 2 sınıfa göre otomatik olarak yeniden yapılandırılmıştır (nc=80 → nc=2).

Model özeti: 3.011.238 parametre, 8.2 GFLOPs. Bu hafif yapı, modelin Tesla T4 GPU üzerinde görüntü başına yaklaşık 2,5 ms gibi çok düşük bir sürede çalışmasını sağlar.

3.2 Veri Artırımı (Data Augmentation)

YOLOv8, eğitim sırasında veri artırımını dahili olarak ve otomatik uygular. Ara sınavda olduğu gibi manuel bir ImageDataGenerator tanımlamaya gerek kalmamıştır. Eğitimde aktif olan başlıca dönüşümler:

- Mozaik (mosaic): Dört görüntünün birleştirilmesi — bağlam çeşitliliği sağlar.
- HSV renk oynaması (hsv_h, hsv_s, hsv_v): Renk/parlaklık değişimleri.
- Yatay çevirme (fliplr=0.5): Görüntülerin yatayda aynalanması.
- Ölçekleme ve kaydırma (scale, translate): Geometrik dönüşümler.
- Rastgele silme (erasing) ve hafif bulanıklaştırma (Blur/CLAHE).

Bu dönüşümler modelin farklı koşullardaki görüntülere karşı dayanıklılığını ve genelleme yeteneğini artırmıştır.


3.3 Eğitim Hiperparametreleri

Parametre	Değer
Model	yolov8n.pt (COCO ön-eğitimli)
Epoch	50 (EarlyStopping ile 25'te durdu)
Görüntü boyutu (imgsz)	640 x 640
Batch size	16
Optimizer	auto → AdamW (lr ≈ 0.00167)
Patience (EarlyStopping)	15
Seed	42 (tekrarlanabilirlik)
Donanım	Google Colab — Tesla T4 GPU

Eğitim, EarlyStopping mekanizması sayesinde 25. epoch'ta otomatik durdurulmuştur; en iyi sonuç 10. epoch'ta elde edilmiş ve en iyi ağırlıklar (best.pt) korunmuştur. Bu, hem gereksiz hesaplama maliyetini hem de aşırı öğrenmeyi (overfitting) önlemiştir.

4. Eğitim Süreci

Aşağıdaki grafiklerde eğitim ve doğrulama kayıpları (box_loss, cls_loss, dfl_loss) ile performans metriklerinin (Precision, Recall, mAP50, mAP50-95) epoch boyunca değişimi görülmektedir. Kayıplar düzenli biçimde azalmış, metrikler yaklaşık 10. epoch civarında doygunluğa (plato) ulaşmıştır.



Şekil 1: Eğitim/Doğrulama Kayıpları ve Performans Metrikleri

5. Test Sonuçları ve Performans Metrikleri


5.1 Performans Tablosu

Modelin doğrulama (validation) seti üzerindeki nihai performansı:

Metrik	Genel (all)	negative	positive
mAP@0.5	0.489	0.576	0.402
mAP@0.5:0.95	0.360	0.430	0.293
Precision	0.459	0.549	0.369
Recall	0.775	0.721	0.833

mAP (mean Average Precision), nesne tespitinin temel başarı ölçütüdür. mAP@0.5, tahmin kutusunun gerçek kutuyla en az %50 örtüştüğü (IoU $\geq$ 0.5) durumlardaki ortalama kesinliği; mAP@0.5:0.95 ise 0.5'ten 0.95'e kadar farklı örtüşme eşiklerindeki ortalamayı ifade eder ve daha katı bir ölçüttür.

5.2 Karışıklık Matrisi (Confusion Matrix)




Şekil 2: Karışıklık Matrisi (Satır: Tahmin, Sütun: Gerçek)

Karışıklık matrisi modelin davranışını ayrıntılı biçimde ortaya koymaktadır:

- Gerçek pozitif tümörlerin 53 tanesi doğru şekilde 'positive' olarak tespit edilmiştir; bu, yüksek Recall (0.83) değerini açıklar — model gerçek tümörlerin büyük kısmını kaçırmamaktadır.
- En belirgin hata kaynağı 'background' sütunudur: model, aslında hiçbir nesne bulunmayan arka plan bölgelerinde 161 'negative' ve 93 'positive' yanlış tespit (false positive) üretmiştir.
- Ayrıca gerçek 'negative' örneklerin 82'si yanlışlıkla 'positive' olarak etiketlenmiştir; iki sınıf görsel olarak birbirine yakındır ve ayırt edilmesi zordur.

Bu yanlış pozitif yoğunluğu, modelin düşük Precision (0.46) değerinin temel nedenidir: model 'tümör var' dediğinde önemli oranda yanılmaktadır.


5.3 Precision-Recall Eğrisi



Şekil 3: Precision-Recall Eğrisi ($mAP@0.5 = 0.489$)

PR eğrisinin altında kalan alan $mAP@0.5$ değerine karşılık gelir. Eğri, modelin orta düzeyde bir ayırt edicilik kapasitesine sahip olduğunu göstermektedir.

5.4 Örnek Tespitler



Şekil 4: Validasyon setinden örnek tümör tespitleri (sınıf + güven skoru)

Görselde modelin MR görüntüleri üzerinde ürettiği tespit kutuları, tahmin edilen sınıf ve güven skoruyla birlikte sunulmaktadır.

6. Model Performansının Yorumu

6.1 Genel Değerlendirme

Model, medikal tarama açısından en kritik özellik olan yüksek Recall (0.78) değerine ulaşmıştır; yani gerçek tümörlerin büyük çoğunluğunu yakalamaktadır. Bir tarama (screening) senaryosunda tümörü gözden kaçırmamak, yanlış alarmdan daha önemlidir; bu açıdan modelin davranışı klinik öncelikle uyumludur.

Buna karşılık düşük Precision (0.46), modelin çok sayıda yanlış pozitif ürettiğini göstermektedir. Pratikte bu, modelin bir karar destek aracı olarak kullanılabileceği ancak nihai tanının mutlaka bir uzman tarafından doğrulanması gerektiği anlamına gelir.

6.2 Model Karşılaştırması (Ablation)

Performansı artırmak amacıyla daha büyük bir model (yolov8s) daha uzun süre (100 epoch) eğitilerek bir karşılaştırma deneyi yapılmıştır:

Model	mAP@0.5	mAP@0.5:0.95	Parametre	Hız
YOLOv8n (50 ep)	0.489	0.362	3.0M	2.5 ms
YOLOv8s (100 ep)	0.493	0.355	11.1M	5.1 ms

Modeli 3,7 kat büyötmek ve 4 kat daha uzun eğitmek, performansta anlamlı bir artış sağlamamıştır (mAP@0.5: 0.489 → 0.493). Bu bulgu, performansı sınırlayan asıl faktörün model kapasitesi değil, veri setinin küçüklüğü (893 eğitim görüntüsü) ve görevin doğal zorluğu (MR'da tümör sınırlarının belirsizliği) olduğunu göstermektedir. Bu nedenle, eşit doğruluğa rağmen daha hızlı ve hafif olan YOLOv8n nihai model olarak tercih edilmiştir.

6.3 İyileştirme Önerileri

- Veri miktarının artırılması (daha fazla etiketli MR görüntüsü) en etkili adımdır.
- Güven eşliğinin (confidence threshold) yükseltilmesi, yanlış pozitifleri azaltıp Precision'ı artırabilir (Recall'dan ödün vererek).
- Tıbbi görüntüleme özel ön işleme (kontrast normalizasyonu, kafatası sıyırma) uygulanabilir.
- Çapraz doğrulama (k-fold) ile sonuçların kararlılığı test edilebilir.

7. Sonuç

Bu çalışmada YOLOv8n modeli, transfer learning ve dahili veri artırımı kullanılarak Ultralytics Brain Tumor veri seti üzerinde eğitilmiş ve MR görüntülerinde beyin tümörü tespiti gerçekleştirilmiştir. Model, mAP@0.5 = 0.489 ve Recall = 0.78 değerleriyle, tümörlerin büyük kısmını başarıyla tespit etmiştir. Yapılan ablation deneyi, performansın model boyutundan çok veri setine bağlı olduğunu ortaya koymuş; bu da gelecekteki çalışmalarda öncelikli olarak veri çeşitliliği ve miktarının artırılması gerektiğini göstermiştir.

8. Teslim Edilenler

- Jupyter Notebook (.ipynb): Tüm adımları içeren çalıştırılabilir kod (Google Colab).
- Eğitim ve değerlendirme görselleri: results.png, confusion_matrix.png, BoxPR_curve.png, ornek_tahminler.png.
- Eğitilmiş model ağırlıkları: best.pt.
- Bu rapor (PDF).
- GitHub deposu: Tüm kod ve çıktıları.

Ekler

Ek A — Kullanılan Teknolojiler

- Python 3.12
- Ultralytics YOLOv8 (sürüm 8.4.69)
- PyTorch 2.11 (CUDA 12.8)
- OpenCV, Matplotlib
- Google Colab (Tesla T4 GPU)

Ek B — Veri Seti Kaynağı

Ultralytics Brain Tumor Detection veri seti kullanılmıştır.

URL: <https://docs.ultralytics.com/tr/datasets/detect/brain-tumor/>

GitHub: <https://github.com/durukanEsmeray/beyin-tumoru-yolov8>